

RECRUTADOR INTELIGENTE: IMPLEMENTAÇÃO DE LARGE LANGUAGE MODELS PARA AVALIAÇÃO DE CANDIDATOS BASEADA EM EVIDÊNCIAS

Atividade Avaliativa P2 – Inteligência Artificial

Data: 16/06/2026

Grupo: Gustavo Carvalho Caldeira;
Lucas Gabriel Ferreira da Silva; Rodrigo Barreto Moraes Costa.

Resumo

Este trabalho apresenta o desenvolvimento de uma solução de recrutamento inteligente baseada em Large Language Models (LLMs), utilizando a metodologia Evidence-to-Decision (EtD) para apoiar processos de seleção de candidatos. A aplicação foi implementada em Python utilizando Streamlit e integra o modelo Llama 3.3 (70B) por meio da API da Groq. O sistema realiza análise de currículos, identificação de competências, geração de perguntas de verificação (Verification Follow-Up – VFU) e elaboração de relatórios estruturados contendo classificação, score de compatibilidade, evidências detectadas e recomendação final. Os resultados demonstram a viabilidade da utilização de LLMs como apoio à tomada de decisão baseada em evidências em processos de recrutamento, proporcionando maior consistência, rastreabilidade e padronização das avaliações realizadas.

Palavras-chave: Inteligência Artificial, Large Language Models, Evidence-to-Decision, Recrutamento Inteligente, Streamlit, Avaliação Baseada em Evidências.

1 INTRODUÇÃO

A tomada de decisão em processos de recrutamento e seleção tradicionalmente depende da análise subjetiva realizada por recrutadores humanos. Embora a experiência profissional seja importante nesse contexto, fatores como vieses cognitivos, interpretações inconsistentes e diferenças nos critérios de avaliação podem comprometer a qualidade da decisão final.

Com o avanço da Inteligência Artificial, especialmente dos Large Language Models (LLMs), tornou-se possível automatizar parte desse processo, oferecendo avaliações mais estruturadas e fundamentadas em evidências concretas. Nesse cenário, a metodologia Evidence-to-Decision (EtD) surge como uma abordagem que busca garantir que decisões sejam tomadas com base em dados verificáveis e critérios explícitos.

Este trabalho apresenta o desenvolvimento de uma solução computacional denominada Recrutador Inteligente, implementada em Python com Streamlit e integrada ao modelo Llama 3.3 (70B) da Meta através da API Groq. O sistema conduz uma avaliação baseada em evidências, identificando competências, lacunas e realizando perguntas complementares de verificação antes de emitir uma recomendação final sobre o candidato.

O objetivo principal é demonstrar como LLMs podem ser utilizados para apoiar processos seletivos de forma estruturada, transparente e orientada por evidências.

2 METODOLOGIA

2.1 Metodologia Evidence-to-Decision

A metodologia Evidence-to-Decision (EtD) consiste em um processo estruturado para tomada de decisão baseado em evidências verificáveis. No contexto deste projeto, ela foi aplicada ao recrutamento e seleção de candidatos.

O fluxo metodológico é composto por quatro etapas principais:

Análise Inicial

O sistema analisa simultaneamente a descrição da vaga e o currículo do candidato, identificando:

- Competências exigidas pela vaga;
- Competências comprovadas pelo candidato;
- Lacunas de conhecimento ou experiência;
- Possíveis pontos que exigem validação adicional.

Verification Follow-Up (VFU)

Após a análise inicial, o sistema gera perguntas específicas destinadas a validar competências consideradas críticas ou insuficientemente comprovadas.

O objetivo não é obter respostas genéricas, mas coletar evidências concretas que permitam confirmar ou refutar alegações presentes no currículo.

Tomada de Decisão

Com base nas evidências coletadas durante as rodadas de VFU, o sistema determina se:

- Existe necessidade de aprofundamento adicional;
- As evidências já são suficientes para uma decisão;
- Deve ser gerado o relatório final.

Para evitar interações excessivas, o sistema limita o processo a duas rodadas de verificação.

Relatório Final

Ao final da avaliação, é produzido um relatório estruturado contendo:

- Classificação do candidato;

- Compatibilidade com a vaga;
 - Recomendação final;
 - Nível de confiança;
 - Competências avaliadas;
 - Evidências encontradas;
 - Lacunas identificadas;
 - Justificativa da decisão.
-

2.2 Fluxo de Avaliação

O fluxo operacional da solução pode ser representado pelas seguintes etapas:

1. Inserção da descrição da vaga;
2. Inserção ou upload do currículo;
3. Análise inicial pelo LLM;
4. Identificação de competências e lacunas;
5. Geração da primeira pergunta VFU;
6. Coleta da resposta do candidato;
7. Reavaliação das evidências;
8. Nova VFU ou geração do relatório final;
9. Exibição dos resultados;
10. Exportação do relatório em PDF.

A Figura 1 apresenta o fluxo de avaliação implementado no sistema de recrutamento inteligente, demonstrando como o processo evolui desde a inserção da descrição da vaga e do currículo até a coleta de evidências por meio das Verificações Complementares (VFUs) e a geração do relatório final.




Fig. 1. Fluxo de avaliação de candidatos baseado na metodologia “Evidence-to-Decision” visto anteriormente.

3 ARQUITETURA DA SOLUÇÃO

A aplicação foi desenvolvida seguindo uma arquitetura em camadas, buscando modularidade e facilidade de manutenção.

3.1 Camada de Interface

A interface foi construída utilizando Streamlit, permitindo interação através do navegador web sem necessidade de instalação adicional pelo usuário.

As principais funcionalidades da interface incluem:

- Inserção da API Key;
- Cadastro da vaga;
- Upload de currículo;
- Respostas às perguntas VFU;
- Visualização do relatório final;
- Exportação em PDF.

3.2 Camada de Processamento

Responsável pela lógica de negócio da aplicação:

- Análise inicial;
- Geração de perguntas;
- Processamento das respostas;
- Controle das rodadas de VFU;
- Geração do relatório final.

A Figura 2 apresenta a arquitetura da solução proposta, ilustrando a interação entre a interface web, a camada de processamento, a integração com o modelo de linguagem, os componentes de extração de dados e o módulo responsável pela geração de relatórios e visualizações.




Fig. 2. Arquitetura da solução de recrutamento inteligente baseada em LLM.

3.3 Camada de Inteligência Artificial

A integração com o modelo de linguagem é realizada através da API Groq utilizando o modelo Llama 3.3 (70B).

Essa camada é responsável por:

- Interpretar currículos;
- Avaliar competências;
- Identificar lacunas;
- Gerar perguntas de verificação;

- Elaborar relatórios.

3.4 Camada de Extração de Dados

Permite leitura de currículos nos formatos:

- PDF;
- DOCX;
- TXT.

As bibliotecas utilizadas foram:

- pypdf;
- python-docx.

3.5 Camada de Relatórios

Responsável pela visualização e exportação dos resultados utilizando:

- Plotly para gráficos;
 - ReportLab para geração de PDFs.
-

4 IMPLEMENTAÇÃO

4.1 Tecnologias Utilizadas

Componente	Tecnologia
Interface Web	Streamlit
Linguagem	Python
Modelo de IA	Llama 3.3 (70B)
API	Groq
PDF	pypdf
DOCX	python-docx

Componente	Tecnologia
Gráficos	Plotly
Relatórios	ReportLab
Dados	Pandas

4.2 Prompt de Sistema

O sistema utiliza um prompt especializado para instruir o modelo a atuar como um avaliador técnico baseado em evidências.

As principais diretrizes são:

- Buscar evidências concretas;
- Evitar respostas genéricas;
- Validar competências técnicas;
- Identificar lacunas;
- Limitar o número de VFUs;
- Retornar respostas estruturadas em JSON.

4.3 Extração de JSON

Para garantir robustez na comunicação com o LLM, foi implementado um mecanismo de extração de JSON capaz de recuperar objetos válidos mesmo quando o modelo retorna texto adicional.

Essa estratégia reduz falhas e aumenta a confiabilidade da aplicação.

4.4 Gerenciamento de Conversação

O histórico da entrevista é mantido utilizando o Session State do Streamlit.

Essa abordagem permite:

- Preservação do contexto;
- Continuidade das perguntas;

- Rastreamento das evidências coletadas;
- Consistência das avaliações.

4.5 Geração de Relatórios

Ao final do processo, o sistema gera automaticamente um relatório contendo:

- Compatibilidade;
 - Classificação;
 - Recomendação;
 - Radar de competências;
 - Evidências;
 - Justificativa analítica.
-

5 RESULTADOS

A aplicação foi testada utilizando diferentes cenários simulados de recrutamento, envolvendo descrições de vagas e currículos com perfis variados.

Durante os testes realizados, o sistema demonstrou capacidade de:

- Identificar competências relevantes;
- Detectar lacunas de conhecimento;
- Formular perguntas contextualizadas;
- Coletar evidências adicionais;
- Produzir recomendações coerentes.

Os relatórios gerados apresentaram informações estruturadas e facilmente interpretáveis pelos usuários, contribuindo para maior transparência na tomada de decisão.

Em todos os cenários avaliados, o fluxo foi concluído dentro do limite máximo de duas rodadas de verificação, conforme definido pela metodologia.

Os resultados preliminares indicam que a utilização de LLMs pode contribuir para a redução da subjetividade em processos seletivos, aumentando a consistência e a rastreabilidade das avaliações realizadas.

6 DISCUSSÃO E LIMITAÇÕES

Embora os resultados obtidos sejam promissores, algumas limitações devem ser consideradas.

Primeiramente, a qualidade da avaliação depende diretamente da qualidade das informações fornecidas na descrição da vaga e no currículo do candidato.

Além disso, modelos de linguagem podem ocasionalmente produzir respostas inconsistentes ou JSON malformatado, exigindo mecanismos de tratamento de erros.

Outra limitação é a dependência de conexão com a internet para acesso à API Groq.

Também é importante destacar que o sistema não substitui a decisão humana. Seu papel é fornecer suporte à tomada de decisão baseada em evidências, cabendo ao recrutador interpretar os resultados e realizar a decisão final.

7 CONCLUSÃO

Este trabalho apresentou o desenvolvimento de uma solução de recrutamento inteligente baseada em Large Language Models e fundamentada na metodologia Evidence-to-Decision.

A aplicação demonstrou ser capaz de analisar currículos, identificar competências, detectar lacunas e conduzir entrevistas estruturadas utilizando perguntas de verificação orientadas por evidências.

A utilização do modelo Llama 3.3 integrado à plataforma Streamlit permitiu a construção de uma ferramenta acessível, interativa e de fácil utilização.

Os resultados obtidos indicam que a combinação entre Inteligência Artificial e metodologias baseadas em evidências pode contribuir significativamente para processos seletivos mais consistentes, transparentes e rastreáveis.

Como trabalhos futuros, sugere-se a integração com plataformas ATS (Applicant Tracking Systems), ampliação dos critérios de avaliação e realização de estudos com processos seletivos reais para validação dos resultados em ambientes corporativos.

8 REFERÊNCIAS

GROQ. Groq API Documentation. Disponível em: <https://console.groq.com/docs>. Acesso em: 16 jun. 2026.

META. Llama 3.3 Model Card. Disponível em: <https://llama.meta.com>. Acesso em: 16 jun. 2026.

STREAMLIT. Streamlit Documentation. Disponível em: <https://docs.streamlit.io>. Acesso em: 16 jun. 2026.

SADLER, D. R. Formative assessment and the design of instructional systems. *Instructional Science*, v. 18, p. 119–144, 1989. Acesso em: 16 jun. 2026.

NICOL, D. J.; MACFARLANE-DICK, D. Formative assessment and self-regulated learning: A model and seven principles of good feedback practice. *Studies in Higher Education*, v. 31, n. 2, p. 199–218, 2006. Acesso em: 16 jun. 2026.